Universidade
Politécnica de Tomar
Escola Superior de Tecnologia de Tomar

Probabilidades & Estatística

Formulário

Unidade Departamental de Matemática e Física

Estatística Descritiva

1 Distribuição de frequências

1. Frequência absoluta: F_i, ou n_i, ou ainda f_a, corresponde ao número de vezes que se verifica um determinado fenómeno. Número de vezes que a realização da variável ocorre. Consequentemente $\sum_{i=1}^{k} F_i = n$ ou $\sum_{i=1}^{k} F_i = N$ onde n é o tamanho da amostra e N o tamanho da população.

2. Frequência relativa: f_i ou f_r, com $f_i = \frac{F_i}{N}$, onde F_i é a frequência absoluta e N o tamanho da população. No caso de se tratar de uma amostra, $f_i = \frac{F_i}{n}$. Verifica-se que $\sum_{i=1}^{k} f_i = 1$.

3. Determinação do número de classes (K inteiro, com $4 \leq K \leq 20$):

$$\begin{cases} K = 5 & \text{se} \quad N \leq 25 \\ K = \sqrt{N} & \text{se} \quad N \geq 25 \end{cases} \quad \text{ou} \quad K \approx 1 + \log_2(n) = 1 + 3,22 \log_{10}(n)$$

   - É desejável que as classes tenham amplitude igual, nem sempre sendo possível.
   - A amplitude da classe é dada por: $a = \frac{\text{amplitude total}}{K} = \frac{max - min}{K}$
   - A amplitude de qualquer classe: $a_i = lim_{sup_i} - lim_{inf_i}$, $i = 1, \ldots, K$, com lim_{sup_i} o limite superior da $i-$ésima classe e lim_{inf_i} o limite inferior da $i-$ésima classe.

4. Ponto médio da classe, ou centro de classe (C_i, X_i'): $C_i = \frac{lim_{sup_i} + lim_{inf_i}}{2} = lim_{inf_i} + \frac{a_i}{2}$, com $i = 1, \ldots, K$.

2 Medidas de Estatística Descritiva

2.1 Medidas de localização

2.1.1 Medidas de tendência central

- Média Populacional, μ

Dados não agrupados	Dados discretos agrupados	Dados contínuos agrupados
$\mu = \frac{\sum_{i=1}^{N} X_i}{N}$	$\mu = \frac{\sum_{i=1}^{p} F_i X_i}{N} = \sum_{i=1}^{p} f_i X_i$	$\mu = \frac{\sum_{i=1}^{K} F_i C_i}{N} = \sum_{i=1}^{K} f_i C_i$

- Média Amostral, $\overline{X}$

Dados não agrupados	Dados discretos agrupados	Dados contínuos agrupados
$\overline{X} = \frac{\sum_{i=1}^{n} X_i}{n}$	$\overline{X} = \frac{\sum_{i=1}^{p} F_i X_i}{n} = \sum_{i=1}^{p} f_i X_i$	$\overline{X} = \frac{\sum_{i=1}^{K} F_i C_i}{n} = \sum_{i=1}^{K} f_i C_i$

- Mediana, Me, (adpatável no caso amostral, n). Após ordenação dos dados

Dados não agrupados	Dados discretos agrupados	Dados contínuos agrupados
Se N Ímpar, $Me = X_{\frac{N+1}{2}}$ Se N Par, $Me = \frac{X_{\frac{N}{2}} + X_{\frac{N}{2}+1}}{2}$	Cálculo das frequências absolutas acumuladas e identificar $\frac{N}{2}$	Identificar a classe mediana, para $\sum F_i \geq \frac{N}{2}$, $Me = \ell_i(Me) + \frac{\frac{N}{2} - \sum F(Me-1)}{F(Me)} a(Me)$

- Moda, Mo

Dados não agrupados	Dados discretos agrupados	Dados contínuos agrupados
Valor da variável que se repete mais vezes	Realização da variável com maior frequência	Identificar classe modal, *i.e.*, maior frequência, $Mo = \ell_i(Mo) + \frac{F(Mo+1)}{F(Mo-1)+F(Mo+1)} a(Mo)$

2.1.2 Medidas de ordem

- Quantis, q_i (Quartis: Q_i, Decis: D_i, Percentis: P_i)

  Após ordenação dos dados, para os Quartis, calcular $n_i = \frac{i \times N}{4}$, $i = 1, 2, 3$. Para os Decis, calcular $n_i = \frac{i \times N}{10}$, $i = 1, \ldots, 9$. Para os Percentis, calcular $n_i = \frac{i \times N}{100}$, $i = 1, \ldots, 99$.

Dados não agrupados	Dados discretos agrupados	Dados contínuos agrupados
Se n_i inteiro $q_i = \frac{X_{n_i} + X_{n_i+1}}{2}$ Se n_i não inteiro $q_i = X_{[n_i+1]}$	Determinar frequências acumuladas. Identificar o quantil.	Identificar a classe $q_i = \ell_i(q_i) + \frac{n_i - \sum F(q_i-1)}{F(q_i)} a(q_i)$ Com $n_i = \frac{i \times N}{4}$, $i = 1, 2, 3$; ou $n_i = \frac{i \times N}{10}$, $i = 1, \ldots, 9$; ou $n_i = \frac{i \times N}{100}$, $i = 1, \ldots, 99$

2.2 Medidas de dispersão

- Amplitude Total, R: $R = max(X_i) - min(X_i)$
- Intervalo Inter-Quartílico, IQ: $IQ = Q_3 - Q_1$
- Intervalo Semi-Quartílico, SQ: $SQ = \frac{Q_3 - Q_1}{2}$

- Desvio Médio Populacional, DM

Dados não agrupados	Dados discretos agrupados	Dados contínuos agrupados
$DM = \frac{\sum_{i=1}^{N} \lvert X_i - \mu \rvert}{N}$	$DM = \frac{\sum_{i=1}^{k} F_i \lvert X_i - \mu \rvert}{N} = \sum_{i=1}^{k} f_i \lvert X_i - \mu \rvert$	$DM = \frac{\sum_{i=1}^{k} F_i \lvert C_i - \mu \rvert}{N} = \sum_{i=1}^{k} f_i \lvert C_i - \mu \rvert$

- Desvio Médio Amostral, DM

Dados não agrupados	Dados discretos agrupados	Dados contínuos agrupados
$DM = \frac{\sum_{i=1}^{n} \lvert X_i - \overline{X} \rvert}{n}$	$DM = \frac{\sum_{i=1}^{k} F_i \lvert X_i - \overline{X} \rvert}{n} = \sum_{i=1}^{k} f_i \lvert X_i - \overline{X} \rvert$	$DM = \frac{\sum_{i=1}^{k} F_i \lvert C_i - \overline{X} \rvert}{n} = \sum_{i=1}^{k} f_i \lvert C_i - \overline{X} \rvert$

- Variância Populacional , σ^2

Dados não agrupados	Dados discretos agrupados	Dados contínuos agrupados
$\sigma^2 = \frac{\sum_{i=1}^{N} (X_i - \mu)^2}{N} = \frac{\sum_{i=1}^{N} X_i^2}{N} - \mu^2$	$\sigma^2 = \frac{\sum_{i=1}^{k} F_i (X_i - \mu)^2}{N} = \sum_{i=1}^{k} f_i (X_i - \mu)^2 = \frac{\sum_{i=1}^{N} F_i X_i^2}{N} - \mu^2 = \sum_{i=1}^{k} f_i X_i^2 - \mu^2$	$\sigma^2 = \frac{\sum_{i=1}^{k} F_i (C_i - \mu)^2}{N} = \sum_{i=1}^{k} f_i (C_i - \mu)^2 = \frac{\sum_{i=1}^{N} F_i C_i^2}{N} - \mu^2 = \sum_{i=1}^{k} f_i C_i^2 - \mu^2$

- Variância Amostral (corrigida) , s^2

No que se segue, estabelece-se que a variância amostral (s^2) é sempre a variância amostral corrigida(s'^2), que por simplificação se denotará por s^2.

Dados não agrupados	Dados discretos agrupados	Dados contínuos agrupados
$s^2 = \frac{\sum_{i=1}^{n}(X_i - \overline{X})^2}{n-1} = \frac{\sum_{i=1}^{n} X_i^2 - n\overline{X}^2}{n-1}$	$s^2 = \frac{\sum_{i=1}^{k} F_i(X_i - \overline{X})^2}{n-1} = \frac{\sum_{i=1}^{k} F_i X_i^2 - n\overline{X})^2}{n-1} = \frac{n}{n-1}\sum_{i=1}^{k} f_i(X_i - \overline{X})^2 = \frac{n}{n-1}\left(\sum_{i=1}^{k} f_i X_i^2 - \overline{X}^2\right)$	$s^2 = \frac{\sum_{i=1}^{k} F_i(C_i - \overline{X})^2}{n-1} = \frac{\sum_{i=1}^{k} F_i C_i^2 - n\overline{X}^2}{n-1} = \frac{n}{n-1}\sum_{i=1}^{k} f_i(C_i - \overline{X})^2 = \frac{n}{n-1}\left(\sum_{i=1}^{k} f_i C_i^2 - \overline{X}^2\right)$

- Desvio Padrão: Populacional, $\sigma = +\sqrt{\sigma^2}$ ou Amostral, $s = +\sqrt{s^2}$
- Coeficiente de Variação: Populacional, $C_V(\%) = \frac{\sigma}{\mu} \times 100$ ou Amostral, $C_V(\%) = \frac{s}{\overline{X}} \times 100$
- *Outliers*
  - *outliers* moderados: $X_i < Q_1 - 1,5 \times (Q_3 - Q_1)$ ou $X_i > Q_3 + 1,5 \times (Q_3 - Q_1)$
  - *outliers* severos: $X_i < Q_1 - 3 \times (Q_3 - Q_1)$ ou $X_i > Q_3 + 3 \times (Q_3 - Q_1)$
- Momentos. Estes podem ser em relação à média (centrais - μ_k) ou em relação à origem, μ'_k.

  1. Momento de k$^{\underline{a}}$ ordem: $\mu'_k = \mathbb{E}[x^k] = \int_{-\infty}^{+\infty} f_x(x) \times x^k dx$ no caso de variáveis contínuas ou $\mu'_k = \mathbb{E}[x^k] = \sum_x \left[f_x(x) \times x^k\right]$, no caso de variáveis discretas
  2. Momento de 1$^{\underline{a}}$ ordem: Média, $\mu_1 = \frac{1}{n}\sum_{i=1}^{n} x_i$. No caso do momento ser central, então $\mu = 0$
  3. Momento central de 2$^{\underline{a}}$ ordem: variância, $\mu_2 = \mathbb{E}[(X - \mathbb{E}[X])^2] = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2 = Var[x]$

2.3 Medidas de Assimetria

- 1$^{\underline{o}}$ Coeficiente de Assimetria de Pearson, $-1 \leq G_1 \leq 1$

  Populacional: $G_1 = \frac{\mu - Mo}{\sigma}$ ou Amostral: $G_1 = \frac{\overline{X} - Mo}{s}$

- $2^{\underline{o}}$ Coeficiente de Assimetria de Pearson, $-3 \leq G_2 \leq 3$

  $G_2 = \dfrac{Q_3 + Q_1 - 2Me}{Q_3 - Q_1}$

- Grau de Assimetria

  Populacional: $G = \dfrac{3(\mu - Me)}{\sigma}$ ou Amostral: $G = \dfrac{3(\overline{X} - Me)}{s}$

  Nota:

  - Se $G, G_1, G_2 < 0$, a distribuição diz-se assimétrica negativa

  - Se $G, G_1, G_2 = 0$, a distribuição diz-se simétrica

  - Se $G, G_1, G_2 > 0$, a distribuição diz-se assimétrica positiva

- Momento de $3^{\underline{a}}$ ordem: $\mu_3 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^3$, e a Assimetria (padronizada) $= \dfrac{\mu_3}{\sigma^3}$

  - Se Assimetria < 0, a distribuição diz-se assimétrica negativa

  - Se Assimetria $= 0$, a distribuição diz-se simétrica

  - Se Assimetria > 0, a distribuição diz-se assimétrica positiva

2.4 Medidas de Curtose

- Coeficiente percentílico de curtose, K

  $K = \dfrac{Q_3 - Q_1}{2(P_{90} - P_{10})}$

  Nota:

  - Se $K < 0,263$, a distribuição diz-se *leptocúrtica*

  - Se $K = 0,263$, a distribuição diz-se *mesocúrtica*

  - Se $K > 0,263$, a distribuição diz-se *platicúrtica*

- Momento de $4^{\underline{a}}$ ordem: $\mu_4 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^4$, e a Curtose (padronizada) $= \dfrac{\mu_4}{\sigma^4}$

  - Se Curtose > 3, a distribuição diz-se *leptocúrtica*

  - Se Curtose $= 3$, a distribuição diz-se *mesocúrtica*

  - Se Curtose < 3, a distribuição diz-se *platicúrtica*

2.5 Medidas de Concentração

- Índice de Gini, $0 \leq R \leq 1$

$$R = \frac{\sum_{i=1}^{m-1}(p_i - q_i)}{\sum_{i=1}^{m-1} p_i} = 1 - \frac{\sum_{i=1}^{m-1} q_i}{\sum_{i=1}^{m-1} p_i} \qquad \text{onde} \qquad p_i = \frac{\sum_{j=1}^{i} F_j}{\sum_{j=1}^{m} F_j} \qquad \text{e} \qquad q_i = \frac{\sum_{j=1}^{i} Y_j}{\sum_{j=1}^{m} Y_j}$$

Nota:
- Se $R = 0$ a concentração da distribuição é mínima
- Se $R = 1$ a concentração da distribuição é máxima
- Quanto maior for o valor de R, maior será a concentração da distribuição.

3 Números Índices

- Índices Simples
  - Índice de preços: $P_{i/0} = \frac{p_i}{p_0} \times 100$
  - Índice de quantidades: $Q_{i/0} = \frac{q_i}{q_0} \times 100$
  - Índice de valores: $V_{i/0} = \frac{p_i \times q_i}{p_0 \times q_0} \times 100$
- Índices Agregados
  - Índice de Laspeyres: $L_{p_i} = \frac{\sum p_i \times q_0}{\sum p_0 \times q_0} \times 100$ e $L_{q_i} = \frac{\sum p_0 \times q_i}{\sum p_0 \times q_0} \times 100$
  - Índice de Paasches: $P_{p_i} = \frac{\sum p_i \times q_i}{\sum p_0 \times q_i} \times 100$ e $P_{q_i} = \frac{\sum p_i \times q_i}{\sum p_i \times q_0} \times 100$
  - Índice de Ideal de Fisher: $I_{p_i}^F = \sqrt{L_{p_i} \times P_{p_i}}$ e $I_{q_i}^F = \sqrt{L_{q_i} \times P_{q_i}}$
  - Índice de Preços de Sidwick-Drobish: $I_p^{SD} = \frac{1}{2}\left(\frac{\sum p_i \times q_0}{\sum p_0 \times q_0} + \frac{\sum p_i \times q_i}{\sum p_0 \times q_0}\right) = \frac{1}{2}(L_p + P_p)$
  - Índice de Preços de Marshall-Edgeworth: $I_p^{ME} = \frac{\sum P_i(q_0 + q_i)}{\sum p_0(q_0 + q_i)}$
- Alteração percentual entre o período i e $i+1$: $\Delta = \frac{I_{i+1} - I_i}{I_i} \times 100$
- Deflacção de uma série cronológica: $\frac{\text{preços correntes}}{\text{índice de preços}} \times 100$

Probabilidades

4 Análise Combinatória

- Factorial: $0! = 1$ e $1! = 1$ $\quad n! = n \cdot (n-1) \cdot (n-2) \cdots 3 \cdot 2 \cdot 1$, para $n > 1$
- Análise Combinatória Simples (sem repetição)
  - Arranjos, A_k^n: $A_k^n = \dfrac{n!}{(n-k)!}$, $k \leq n$
  - Permutações, $P_n = A_n^n$: $P_n = n!$

    Se os elementos não forem distintos, e caso se repitam $n_1, n_2, \ldots$, com $n_1 + n_2 + \ldots + n_k = n$, então $P_{n1,n_2,\ldots,n_k} = \dfrac{n!}{n_1! n_2! \ldots n_k!}$
  - Combinações, $C_k^n = \binom{n}{k}$: $C_k^n = \binom{n}{k} \dfrac{n!}{k!(n-k)!}$, $k \leq n$
- Análise Combinatória Completa (com repetição)
  - Arranjos Completos, $\overline{A}_k^n$: $\overline{A}_k^n = n^k$
  - Permutações Completas, $\overline{P}_n$: $\overline{P}_n = n^n$
  - Combinações Completas, $\overline{C}_k^n$: $\overline{C}_k^n = C_k^{n+k-1} = \dfrac{(n+k-1)!}{k!(n-1)!}$
- Binómio de Newton: $(a+b)^n = \displaystyle\sum_{k=0}^{n} \binom{n}{k} a^k b^{n-k}$
- Fórmula de Stirling: $n! \approx \sqrt{2\pi n}\, n^n e^{-n}$

5 Termos e Conceitos Probabilísticos

- Experiência Aleatória: Processo ou experiência cujo resultado não pode ser previsto com certeza, mesmo que todas as condições sejam conhecidas e repetidas de forma idêntica.
- Acontecimento Elementar: acontecimento elementar (ou evento elementar) é um único resultado possível de uma experiência aleatória. Este não pode ser decomposto em outros eventos mais simples dentro do espaço amostral.
- Espaço de Resultados, Ω: O espaço de resultados (espaço amostral), é o conjunto de todos os resultados possíveis de uma experiência aleatória.
- Acontecimento, A: Qualquer subconjunto de Ω

- Acontecimento Certo: É o acontecimento constituído por todos os elementos de Ω, $A = \Omega$
- Acontecimento Impossível: É o acontecimento que nunca ocorre $A = \emptyset$
- Acontecimentos Incompatíveis (Mutuamente Exclusivos): Dados dois acontecimentos A e B, dizem-se incompatíveis se e só se $A \cap B = \emptyset$
- Acontecimentos Contrários: Dados dois acontecimentos A e B, dizem-se contrários se e só se $A \cap B = \emptyset$ e $A \cup B = \Omega$
- Acontecimentos Equiprováveis: Dois ou mais acontecimentos (ou resultados) são chamados de equiprováveis quando têm a mesma probabilidade de ocorrer

6 Álgebra dos Acontecimentos

- Acontecimento Complementar, $\overline{A}$: É o acontecimento que consiste na não realização de A, *i.e.*, $\overline{A} = \{W : W \notin A \wedge W \in \Omega\}$
- Reunião de Acontecimentos, $A \cup B$: É o acontecimento que consiste na realização de pelo menos um dos acontecimentos A ou B, $A \cup B = \{W : W \in A \vee W \in B\}$
- Intersecção de Acontecimentos, $A \cap B$: É o acontecimento que consiste na realização simultânea de dois acontecimentos A e B, $A \cap B = \{W : W \in A \wedge W \in B\}$
- Diferença de Acontecimentos, $A - B = A \setminus B$: É o acontecimento que se realiza quando ocorre A e não ocorre B, $A - B = A \setminus B = \{W : W \in A \wedge W \notin B\} = A \cap \overline{B}$

7 Propriedades Operatórias

- Propriedade Comutativa: $A \cup B = B \cup A$; $A \cap B = B \cap A$
- Propriedade Associativa: $A \cup (B \cup C) = (A \cup B) \cup C$; $A \cap (B \cap C) = (A \cap B) \cap C$
- Propriedade Distributiva: $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$; $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
- Elemento Neutro: $A \cup \emptyset = A$; $A \cap \Omega = A$
- Elemento Absorvente: $A \cup \Omega = \Omega$; $A \cap \emptyset = \emptyset$
- Idempotência: $A \cup A = A$; $A \cap A = A$
- Lei do Complemento: $A \cup \overline{A} = \Omega$; $A \cap \overline{A} = \emptyset$
- Lei de Morgan: $\overline{(A \cup B)} = \overline{A} \cap \overline{B}$; $\overline{(A \cap B)} = \overline{A} \cup \overline{B}$

8 Conceito de Probabilidade

- Definição clássica (Laplace): $P(A) = \dfrac{\#\text{ casos favoráveis à ocorrência de A}}{\#\text{ casos possíveis}}$, $A \subseteq \Omega$
- Definição frequencista (Bernoulli): $\forall \varepsilon > 0, \lim\limits_{n\to\infty} P\left(|f_n(A) - p| \leq \varepsilon\right) = 1$, $p \in [0,1]$ é a probabilidade de A e $f_n(A)$ a frequência relativa da realização de A.
- Definição axiomática (Kolmogorov): Chama-se probabilidade à função $P(\cdot)$ que associa a todo o acontecimento A definido em Ω, um número real e que satisfaz os seguintes axiomas:
  1. $P(A) \geq 0$, para todo o $A \subseteq \Omega$
  2. $P(\Omega) = 1$
  3. $P\left(\bigcup\limits_i A_i\right) = \sum\limits_i P(A_i)$, sendo $A_1, A_2, \ldots$ acontecimentos, em número finito ou infinito numerável, tais que $A_i \cap A_j = \emptyset$, para $i \neq j$
- Consequências da axiomática
  1. Se $A \subseteq B$, então $P(A) \leq P(B)$
  2. $0 \leq P(A) \leq 1$, para qualquer $A \subseteq \Omega$
  3. $P(\overline{A}) = 1 - P(A)$
  4. $P(\emptyset) = 0$
  5. $P(A - B) = P(A \cap \overline{B}) = P(A) - P(A \cap B)$
  6. $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
  7. $P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$
  8. $P\left(\bigcup\limits_{i=1}^{n} A_i\right) = \sum\limits_{i=1}^{n} P(A_i) - \sum\limits_{i=1}^{n-1}\sum\limits_{j=i+1}^{n} P(A_i \cap A_j) + \sum\limits_{i=1}^{n-2}\sum\limits_{j=i+1}^{n-1}\sum\limits_{k=j+1}^{n} P(A_i \cap A_j \cap A_k) + \cdots + (-1)^{n+1} P\left(\bigcap\limits_{i=1}^{n} A_i\right)$
- Probabilidades Condicionadas: Sejam $A, B \subseteq \Omega$, $P(B) > 0$, designa-se probabilidade de A condicionada por B, à probabilidade de se realizar A depois de se ter realizado B
  1. $P(A|B) = \dfrac{P(A \cap B)}{P(B)}$
  2. $P(A \cap B) = P(A|B)P(B)$, com $P(B) > 0$, ou $P(A \cap B) = P(B|A)P(A)$, $P(A) > 0$
  3. $P(A \cap B \cap C) = P(C|A \cap B)P(B|A)P(A)$, com $P(A \cap B)$, com $P(A \cap B) > 0$

4. $P\left(\bigcap_{i=1}^{n}\right) = P\left(A_n|\bigcap_{i=1}^{n-1} A_i\right) P\left(A_{n-1}|\bigcap_{i=1}^{n-2} A_i\right) \cdots P(A_3|A_1 \cap A_2)P(A_2|A_1)P(A_1)$, com $P\left(\bigcap_{i=1}^{n-1} A_i\right) > 0$
5. $P(\overline{A}|B) = 1 - P(A|B)$
6. $P(\overline{A}|\overline{B}) = 1 - P(A|\overline{B})$

- Partição: Um conjunto de acontecimentos $\{A_1, A_2, \ldots, A_n\}$ diz-se uma partição de Ω, se e só se,
  1. $A_i \cap A_j = \emptyset$, para $i \neq j$, e $i, j = 1, 2, \ldots, n$
  2. $\bigcup_{i=1}^{n} A_i = \Omega$
- Teorema da Probabilidade Total: Se $\{A_1, A_2, \ldots, A_n\}$ é uma participação de Ω, tal que $P(A_i) > 0$, $i = 1, 2, \ldots, n$, então para todo o acontecimento B definido em Ω, tem-se $P(B) = \sum_{i=1}^{n} P(B|A_i)P(A_i)$
- Teorema de Bayes: Se $\{A_1, A_2, \ldots, A_n\}$ é uma participação de Ω, tal que $P(B) > 0$, então $P(A_i|B) = \dfrac{P(B|A_i)P(A_i)}{\sum_{i=1}^{n} P(B|A_i)P(A_i)}$, para $i = 1, 2, \ldots, n$
- Acontecimentos Independentes: dois acontecimentos A e B, de probabilidade não nula, dizem-se independentes quando a realização de um não afecta a probabilidade de realização do outro ou vice-versa, *i.e.*, se $P(A|B) = P(A)$ ou se $P(B|A) = P(B)$.
  1. A e B são independentes se e só se $P(A \cap B) = P(A) \times P(B)$
  2. A, B e C são independentes se e só se,
     (a) $P(A \cap B) = P(A) \times P(B)$
     (b) $P(A \cap C) = P(A) \times P(C)$
     (c) $P(B \cap C) = P(B) \times P(C)$
     (d) $P(A \cap B \cap C) = P(A) \times P(B) \times P(C)$
  3. Dados n acontecimentos, ter-se-ão que verificar $C_2^n + C_3^n + \cdots + C_n^n = 2^n - n - 1$ condições, para que sejam independentes, *i.e.*, terão de ser independentes 2 a 2, 3 a 3, ..., n a n, $P(A_1 \cap A_2 \cap \cdots \cap A_n) = P(A_1) \times P(A_2) \times \cdots \times P(A_n)$

Variáveis Aleatórias

9 Função distribuição

- Definição: $F(x) = P(X \leq x)$, $\forall x \in \mathbb{R}$
- Propriedades:
  1. $0 \leq F(x) \leq 1$, $\forall x \in \mathbb{R}$
  2. $F(-\infty) = \lim_{n \to -\infty} F(x) = 0$ e $F(+\infty) = \lim_{n \to +\infty} F(x) = 1$
  3. F é uma função não-decrescente, isto é, $\forall x_1, x_2 \in \mathbb{R} : x_1 > x_2 \Rightarrow F(x_1) \geq F(x_2)$
  4. F é uma função contínua à direita, isto é, $\lim_{x \to a^+} F(x) = F(a)$
  5. $P(X = a) = F(a) - \lim_{x \to a^-} F(x)$
  6. F é contínua em a se e só se $P(X = a) = 0$
  7. $P(X < a) = P(X \leq a) - P(X = a) = F(a) - P(X = a)$
  8. $P(X > a) = 1 - P(X \leq a) = 1 - F(a)$
  9. $P(X \geq a) = 1 - P(X < a)$
  10. $P(a < X \leq b) = F(b) - F(a)$
  11. $P(a < X < b) = P(a < X \leq b) - P(X = b)$
  12. $P(a \leq X < b) = P(a < X < b) + P(X = a)$
  13. $P(a \leq X \leq b) = P(a \leq X < b) + P(X = b)$

10 Variáveis Aleatórias Discretas

- Função probabilidade: Se a variável aleatória discreta X assume os valores $x_1, x_2, \ldots, x_n, \ldots$, então

$$f(x) = \begin{cases} P(X = x) & \text{se} \quad x = x_i \\ 0 & \text{se} \quad x \neq x_i \end{cases}$$

  $i = 1, 2, \ldots, n, \ldots$
- Condições e Propriedades
  1. $f(x) \geq 0$, $\forall x \in \mathbb{R}$
  2. $\sum_i f(x_i) = 1$
  3. $F(x) = P(X \leq x) = \sum_{x_i \leq x} f(x_i)$

11 Variáveis Aleatórias Contínuas

- Função densidade de probabilidade: é a função real de variável real que verifica $F(x) = \int_{-\infty}^{x} f(t)dt$
- Condições e Propriedades
  1. $f(x) \geq 0, \forall x \in \mathbb{R}$
  2. $\int_{-\infty}^{+\infty} f(x)dx = 1$
  3. Se F é uma função contínua em $\mathbb{R}$, $P(X = x) = 0$
  4. $F'(x) = f(x)$
  5. $P(X < a) = P(X \leq a) = F(a) = \int_{-\infty}^{a} f(x)dx$
  6. $P(X > a) = 1 - P(X \leq a) = 1 - F(a) = 1 - \int_{-\infty}^{a} f(x)dx$
  7. $P(X > a) = P(X \geq a) = \int_{a}^{+\infty} f(x)dx$
  8. $P(a \leq X < b) = P(a \leq X \leq b) = P(a < X \leq B) = P(a < X < b) = F(b) - F(a) = \int_{a}^{b} f(x)dx$

12 Valor Esperado ou Média

- Valor Esperado ou Média (variável discreta): $\mu = \mathbb{E}[X] = \sum_{i} x_i f(x_i)$
- Valor Esperado ou Média (variável contínua): $\mu = \mathbb{E}[X] = \int_{-\infty}^{+\infty} xf(x)dx$
- $\mathbb{E}[k] = k$, $k \in \mathbb{R}$
- $\mathbb{E}[kX] = k\mathbb{E}[X]$, $k \in \mathbb{R}$
- $\mathbb{E}[X \pm Y] = \mathbb{E}[X] \pm \mathbb{E}[Y]$
- $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$, a, $b \in \mathbb{R}$
- $\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$, se X e Y independentes
- $\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y] + Cov(X, Y)$

- $\mathbb{E}[X - \mathbb{E}[X]] = 0$
- Se g for uma função de contradomínio $\mathbb{R}$ e $Y = g(X)$ tem-se
  - Caso discreto: $\mathbb{E}[Y] = \mathbb{E}\left[g(X)\right] = \sum_i g(x_i)f(x_i)$
  - Caso contínuo: $\mathbb{E}[Y] = \mathbb{E}\left[g(X)\right] = \sum_i g(x_i)f(x_i)$ ou $\mathbb{E}[Y] = \mathbb{E}\left[g(X)\right] = \int_{-\infty}^{+\infty} g(x)f(x)dx$

13 Variância

1. Variância (variável discreta) $V(X) = \mathbb{E}\left[(X - \mu)^2\right] = \sum_i (x_i - \mu)^2 f(x_i)$
2. Variância (variável contínua): $V(X) = \mathbb{E}\left[(X - \mu)^2\right] = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x)dx$
3. $V(k) = 0$, $k \in \mathbb{R}$
4. $V(kX) = k^2 V(X)$, $k \in \mathbb{R}$
5. $V(X \pm Y) = V(X) + V(Y)$, se X e Y independentes
6. $V(X \pm Y) = V(X) + V(Y) \pm 2Cov(X, Y)$, com $Cov(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y]$
7. $V(aX + b) = a^2 V(X)$, a, $b \in \mathbb{R}$
8. $V(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$
9. $\sigma = \sigma_X = +\sqrt{V(X)}$

Distribuições de Probabilidade

14 Distribuições Teóricas Discretas

1. Distribuição de Bernoulli, $X \sim Ber(p)$

   - Distribuição de probabilidade discreta que descreve o comportamento de uma experiência aleatória com apenas dois resultados possíveis, com p a probabilidade de sucesso
   - Parâmetros: $\mathbb{E}[X] = p$; $V(X) = p \times q = p \times (1-p)$
   - Função probabilidade: $f(x) = p^x \times (1-p)^{1-x}$, $x = 0, 1$ e $0 \leq p \leq 1$

2. Distribuição Binomial, $X \sim B(n; p)$

   - Distribuição de probabilidade discreta que modela o número de sucessos em n ensaios de Bernoulli independentes, cada um com a mesma probabilidade de sucesso p
   - Parâmetros: $\mathbb{E}[X] = n \times p$; $V(X) = n \times p \times q = n \times p \times (1-p)$
   - Função probabilidade: $f(x) = \binom{n}{x} \times p^x \times (1-p)^{n-x}$, $x = 0, 1, \ldots, n$ e $0 \leq p \leq 1$

3. Distribuição Hipergeométrica, $X \sim H(N; K; n)$

   - Distribuição de probabilidade discreta que descreve a probabilidade de obter x sucessos em n extrações sem reposição de uma população finita de tamanho N, que contém K elementos de sucesso e $N - K$ de fracasso.
   - Parâmetros: $\mathbb{E}[X] = n \times \dfrac{K}{N}$; $V(X) = n \times \dfrac{K}{N} \times \left(1 - \dfrac{K}{N}\right) \times \dfrac{N-n}{N-1}$
   - Função probabilidade: $f(x) = \dfrac{\binom{K}{x}\binom{N-K}{n-x}}{\binom{N}{n}}$

4. Distribuição de Poisson, $X \sim P(\lambda)$

   - Distribuição de probabilidade discreta que modela o número de ocorrências de um evento raro num intervalo fixo de tempo, espaço, área ou volume, quando essas ocorrências são independentes e acontecem a uma taxa constante
   - Parâmetros: $\mathbb{E}[X] = \lambda$; $V(X) = \lambda$
   - Função probabilidade: $f(x) = \dfrac{e^{-\lambda}\lambda^x}{x!}$

15 Distribuições Teóricas Contínuas

1. Distribuição Normal, $X \sim N(\mu; \sigma^2)$

   - Distribuição normal, distribuição de Gauss ou distribuição com curva de sino, é uma distribuição de probabilidade contínua que modela fenómenos naturais ou sociais que se distribuem de forma simétrica em torno de uma média
   - Parâmetros: $\mathbb{E}[X] = \mu$; $V(X) = \sigma^2$
   - Se $X \sim N(\mu; \sigma^2)$ então $Z = \dfrac{X - \mu}{\sigma} \sim N(0; 1)$
   - Função densidade de probabilidade: $f(x) = \dfrac{1}{\sigma\sqrt{2\pi}}\, e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$

2. Distribuição Qui-Quadrado, $X \sim \chi^2_n$

   - Parâmetros: $\mathbb{E}[X] = n$; $V(X) = 2n$
   - Função densidade de probabilidade: $f(x) = \dfrac{1}{2^{\frac{n}{2}}\,\Gamma\left(\frac{n}{2}\right)}\, e^{-\frac{x}{2}}\, x^{\frac{n}{2}-1}$, $n \in \mathbb{N}$ e $x > 0$

     onde a função gama, Γ, é definida por: $\Gamma(u) = \displaystyle\int_0^{+\infty} x^{u-1}\, e^{-x} dx$, $u > 0$

3. Distribuição t-*Student*, $X \sim t_n$

   - Distribuição de probabilidade contínua usada principalmente quando se estima a média de uma população normal com amostras pequenas ($n < 30$) e variância populacional desconhecida. Esta é semelhante à distribuição normal, mas tem caudas mais largas, o que dá mais margem para incertezas que surgem em amostras pequenas
   - Parâmetros: $\mathbb{E}[X] = 0$; $V(X) = \dfrac{n}{n-2}$, $n > 2$
   - Função densidade de probabilidade: $f(x) = \dfrac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\,\Gamma\left(\frac{n}{2}\right)} \left(1 + \dfrac{x^2}{2}\right)^{-\frac{n+1}{2}}$, $n \in \mathbb{N}$ e $x \in \mathbb{R}$

4. Distribuição Fisher-Snedcor (F-Snedcor), $X \sim F_{m,n}$

   - Parâmetros: $\mathbb{E}[X] = \dfrac{n}{n-2}$; $V(X) = \dfrac{2n^2(m+n-2)}{m(n-2)^2(n-4)}$, $n > 4$

- Função densidade de probabilidade: $f(x) = \dfrac{\Gamma\left(\dfrac{n+m}{2}\right)}{\Gamma\left(\dfrac{m}{2}\right)\Gamma\left(\dfrac{n}{2}\right)} \left(\dfrac{m}{n}\right)^{\frac{m}{2}} \dfrac{x^{\frac{m-2}{2}}}{\left(1+\frac{m}{n}x\right)^{\frac{m+n}{2}}}$, $m, n \in \mathbb{N}$ e $x > 0$

5. Aproximações
   - Se $X \sim B(n;p)$, e $n \to +\infty$, $p \to 0$, ($n > 20$ e $p < 0,05$), então $X \overset{a}{\sim} P(\lambda)$, com $\lambda = np$
   - Se $X \sim B(n;p)$, e $n \to +\infty$, $p \cong 0,5$, ($np \geq 5$ e $nq \geq 5$), então $X \overset{a}{\sim} N(\mu;\sigma^2)$, com $\mu = np$ e $\sigma^2 = npq$
   - $X \sim P(\lambda)$, e $\lambda \to +\infty$, ($\lambda > 20$), então $X \overset{a}{\sim} N(\mu;\sigma^2)$, com $\mu = \lambda$ e $\sigma^2 = \lambda$

16 Distribuições Amostrais

16.1 Média, μ

1. Condições: População Normal, σ conhecido
   (a) Variável fulcral: $\dfrac{\overline{X} - \mu}{\dfrac{\sigma}{\sqrt{n}}} \sim N(0,1)$
   (b) Intervalo de confiança: $\overline{X} \pm z\left(\frac{\alpha}{2}\right)\dfrac{\sigma}{\sqrt{n}}$
2. Condições: População Qualquer, σ conhecido, amostra de grandes dimensões ($n > 30$)
   (a) Variável fulcral: $\dfrac{\overline{X} - \mu}{\dfrac{\sigma}{\sqrt{n}}} \overset{a}{\sim} N(0,1)$
   (b) Intervalo de confiança: $\overline{X} \pm z\left(\frac{\alpha}{2}\right)\dfrac{\sigma}{\sqrt{n}}$
3. Condições: População Qualquer, σ desconhecido, amostra de grandes dimensões ($n > 30$)
   (a) Variável fulcral: $\dfrac{\overline{X} - \mu}{\dfrac{s}{\sqrt{n}}} \overset{a}{\sim} N(0,1)$, com s o desvio padrão amostral
   (b) Intervalo de confiança: $\overline{X} \pm z\left(\frac{\alpha}{2}\right)\dfrac{s}{\sqrt{n}}$
4. Condições: População Normal, σ desconhecido, amostra de pequenas dimensões ($n \leq 30$)

(a) Variável fulcral: $\dfrac{\overline{X}-\mu}{\frac{s}{\sqrt{n}}} \sim t_{n-1}$, com s o desvio padrão amostral

(b) Intervalo de confiança: $\overline{X} \pm t_{n-1}\left(\frac{\alpha}{2}\right)\dfrac{s}{\sqrt{n}}$

16.2 Variância, σ^2

1. Condições: População Normal

   (a) Variável fulcral: $\dfrac{(n-1)s^2}{\sigma^2} \sim \chi^2_{n-1}$

   (b) Intervalo de confiança: $\dfrac{(n-1)s^2}{\chi^2_{n-1}\left(\frac{\alpha}{2}\right)}\ ;\ \dfrac{(n-1)s^2}{\chi^2_{n-1}\left(\frac{1-\alpha}{2}\right)}$

16.3 Proporção, p

1. Condições: População de Bernoulli, amostra de grandes dimensões ($n > 30$)

   (a) Variável fulcral: $\dfrac{\hat{p}-p}{\sqrt{\frac{p(1-p)}{n}}} \overset{a}{\sim} N(0;1)$, com $\hat{p} = \dfrac{X}{n}$

   (b) Intervalo de confiança: $\hat{p} \pm z\left(\frac{\alpha}{2}\right)\sqrt{\dfrac{\hat{p}(1-\hat{p})}{n}}$

   Nota: Considerando que $\hat{p}$ é um bom estimador para p, substituí-se este na expressão para o intervalo de confiança.

16.4 Diferença de Médias, $\mu_1 - \mu_2$

De notar que quando se pretende testar $\mu_1 = \mu_2$, é equivalente testar $\mu_1 - \mu_2 = 0$

1. Condições: Duas populações Normais, σ_1 e σ_2 conhecidos, amostras independentes

   (a) Variável fulcral: $\dfrac{\left(\overline{X}_1 - \overline{X}_2\right) - (\mu_1 - \mu_2)}{\sqrt{\dfrac{\sigma_1^2}{n_1} + \dfrac{\sigma_2^2}{n_2}}} \sim N(0;1)$

   (b) Intervalo de confiança: $\left(\overline{X}_1 - \overline{X}_2\right) \pm z\left(\frac{\alpha}{2}\right)\sqrt{\dfrac{\sigma_1^2}{n_1} + \dfrac{\sigma_2^2}{n_2}}$

2. Condições: Duas populações Quaisquer, σ_1 e σ_2 conhecidos, amostras independentes de grandes dimensões ($n_1 > 30$ e $n_2 > 30$)

(a) Variável fulcral: $\dfrac{\left(\overline{X}_1 - \overline{X}_2\right) - (\mu_1 - \mu_2)}{\sqrt{\dfrac{\sigma_1^2}{n_1} + \dfrac{\sigma_2^2}{n_2}}} \overset{a}{\sim} N(0;1)$

(b) Intervalo de confiança: $\left(\overline{X}_1 - \overline{X}_2\right) \pm z\left(\frac{\alpha}{2}\right)\sqrt{\dfrac{\sigma_1^2}{n_1} + \dfrac{\sigma_2^2}{n_2}}$

3. Condições: Duas populações Quaisquer, σ_1 e σ_2 desconhecidos, amostras independentes de grandes dimensões ($n_1 > 30$ e $n_2 > 30$)

(a) Variável fulcral: $\dfrac{\left(\overline{X}_1 - \overline{X}_2\right) - (\mu_1 - \mu_2)}{\sqrt{\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}}} \overset{a}{\sim} N(0;1)$

(b) Intervalo de confiança: $\left(\overline{X}_1 - \overline{X}_2\right) \pm z\left(\frac{\alpha}{2}\right)\sqrt{\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}}$

4. Condições: Duas populações Normais, σ_1 e σ_2 desconhecidos mas iguais ($\sigma_1 = \sigma_2$), amostras independentes de pequenas dimensões ($n_1 \leq 30$ e $n_2 \leq 30$)

(a) Variável fulcral: $\dfrac{\left(\overline{X}_1 - \overline{X}_2\right) - (\mu_1 - \mu_2)}{s\sqrt{\dfrac{1}{n_1} + \dfrac{1}{n_2}}} \sim t_{n_+ n_2 - 2}$, com $s = \sqrt{\dfrac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1 + n_2 - 2}}$

(b) Intervalo de confiança: $\left(\overline{X}_1 - \overline{X}_2\right) \pm t_{n_1+n_2-2}\left(\frac{\alpha}{2}\right) s\sqrt{\dfrac{1}{n_1} + \dfrac{1}{n_2}}$

5. Condições: Duas populações Normais, σ_1 e σ_2 desconhecidos, amostras independentes de pequenas dimensões ($n_1 \leq 30$ e $n_2 \leq 30$)

(a) Variável fulcral: $\dfrac{\left(\overline{X}_1 - \overline{X}_2\right) - (\mu_1 - \mu_2)}{\sqrt{\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}}} \overset{a}{\sim} t_{gl}$, com $gl = \dfrac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1 - 1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2 - 1}}$

Nota: gl é a componente inteira resultante da fórmula anterior.

(b) Intervalo de confiança: $\left(\overline{X}_1 - \overline{X}_2\right) \pm t_{gl}\left(\frac{\alpha}{2}\right)\sqrt{\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}}$

16.5 Rácio de Variâncias, $\dfrac{\sigma_1^2}{\sigma_2^2}$

De notar que quando se pretende testar $\sigma_1 = \sigma_2$, é equivalente testar $\dfrac{\sigma_1}{\sigma_2} = 1$

1. Condições: Duas populações Normais, amostras independentes

(a) Variável fulcral: $\frac{s_1^2}{s_2^2}\frac{\sigma_2^2}{\sigma_1^2} \sim F_{n_1-1;n_2-1}$

(b) Intervalo de confiança: $\frac{1}{F_{n_1-1;n_2-1}\left(\frac{\alpha}{2}\right)}\frac{S_1^2}{s_2^2}\,;\,\frac{1}{F_{n_1-1;n_2-1}\left(1-\frac{\alpha}{2}\right)}\frac{S_1^2}{s_2^2}$

16.6 Diferença de Proporções, $p_1 - p_2$

De notar que quando se pretende testar $p_1 = p_2$, é equivalente testar $p_1 - p_2 = 0$

1. Condições: Duas populações de Bernoulli, amostras independentes de grandes dimensões ($n_1 > 30$ e $n_2 > 30$)

   (a) Variável fulcral: $\frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}} \overset{a}{\sim} N(0;1)$, com $\hat{p}_1 = \frac{X_1}{n_1}$ e $\hat{p}_2 = \frac{X_2}{n_2}$

   Nota: não se conhecendo o desvio-padrão de $(\hat{p}_1 - \hat{p}_2)$, o procedimento pode passar por substituir p_1 e p_2 por $\hat{p} = \frac{X_1 + X_2}{n_1 + n_2}$, pelo que

   $$\frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\hat{p}_1(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \overset{a}{\sim} N(0;1)$$

   (b) Intervalo de confiança: $(\hat{p}_1 - \hat{p}_2) \pm z\left(\frac{\alpha}{2}\right)\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}$

   Considerando que p_1 e p_2 aparecem na expressão, precisamente os parâmetros a estimar, atendendo que $\hat{p}$ é um bom estimador para p, podemos apontar 2 alternativas

   - atendendo que $\hat{p}$ é um bom estimador para p, podemos escrever
     $(\hat{p}_1 - \hat{p}_2) \pm z\left(\frac{\alpha}{2}\right)\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$
   - de forma mais "conservadora", poder-se-á substituir $p_1(1-p_1)$ e $p_2(1-p_2)$ na expressão que seja mais desfavorável para a estimação do intervalo de confiança, *i.e.*, quando estas expressões têm o seu máximo. Assim, $p(1-p) = p - p^2$, é máximo quando $p = 0,5$, e como tal $p(1-p) = 0,25$, pelo que a expressão do intervalo de confiança passa a ser
     $(\hat{p}_1 - \hat{p}_2) \pm z\left(\frac{\alpha}{2}\right)\sqrt{\frac{0,25}{n_1} + \frac{0,25}{n_2}}$

Regressão Linear Simples

17 Modelo

A relação matemática entre uma variável dependente (Y) e uma variável independente (X), é estabelecida através da equação $Y = \beta_0 + \beta_1 X + \varepsilon$, de onde se obtém o modelo estimado dado por, $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$, com $Y = \hat{Y} + \hat{\varepsilon}$, onde $\mathbb{E}[\hat{\varepsilon}] = 0$.

17.1 Estimadores

Estimação pontual dos parâmetros,

$$\hat{\beta}_1 = \frac{n\sum_i x_i y_i - \sum_i x_i \sum_i y_i}{n\sum_i x_i^2 - \left(\sum_i x_i\right)^2} = \frac{S_{XY}}{S_X^2} \qquad \text{e} \qquad \hat{\beta}_0 = \overline{Y} - \hat{\beta}_1 \overline{X}$$

onde

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} x_i \qquad\qquad \overline{Y} = \frac{1}{n}\sum_{i=1}^{n} y_i$$

$$S_{XY} = \frac{\sum_{i=1}^{n}(x_i - \overline{X})(y_i - \overline{Y})}{n} = \frac{\sum_{i=1}^{n} x_i y_i}{n} - \overline{XY}$$

$$S_X^2 = \frac{\sum_{i=1}^{n}(x_i - \overline{X})^2}{n} = \frac{\sum_{i=1}^{n} x_i^2}{n} - \overline{X}^2 \qquad\qquad S_Y^2 = \frac{\sum_{i=1}^{n}(y_i - \overline{Y})^2}{n} = \frac{\sum_{i=1}^{n} y_i^2}{n} - \overline{Y}^2$$

$$S_{\hat{\beta}_0}^2 = S^2\left(\frac{\sum_{i=1}^{n} x_i^2}{n\sum_{i=1}^{n}(x_i - \overline{X})^2}\right) \qquad S_{\hat{\beta}_1}^2 = \frac{S^2}{\sum_{i=1}^{n}(x_i - \overline{X})^2} \qquad S^2 = \frac{\sum_{i=1}^{n} \varepsilon_i^2}{n-2}$$

$$S_{\hat{\beta}_0,\hat{\beta}_1} = S^2\left[\frac{-\overline{X}}{\sum_{i=1}^{n}(x_i - \overline{X})^2}\right]$$

Estimação, por intervalo de confiança, dos parâmetros: $\beta_j \in \hat{\beta}_j \pm t_{n-2}(\frac{\alpha}{2})\, S_{\hat{\beta}_j} \quad , j = 0, 1$

$$TSS = RSS + ESS \qquad TSS = \sum_{i=1}^{n}(y_i - \overline{Y})^2 \qquad RSS = \sum_{i=1}^{n}(\hat{y}_i - \overline{Y})^2 \qquad ESS = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

17.2 Testes de hipóteses e Previsão

$$H_0 : \beta_i = 0 \quad vs \quad H_1 : \beta_i \neq 0 \qquad T = \frac{\hat{\beta}_i}{S_{\hat{\beta}_i}} \sim t_{n-2} \quad , i = 0, 1$$

Intervalo de confiança: $y_0 \in \hat{y}_0 \pm t_{n-2}(\frac{\alpha}{2})\, S \sqrt{\frac{1}{n} + \frac{(x_0 - \overline{X})^2}{\sum_{i=1}^{n}(x_i - \overline{X})^2}}$

17.3 Coeficiente de Correlação Linear de Pearson, $-1 \leq \rho, r \leq 1$

$$r_{X,Y} = \frac{n\sum_{i=1}^{n} x_i y_i - \sum_{i=1}^{n} x_i \sum_{i=1}^{n} y_i}{\sqrt{\left[n\sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i\right)^2\right]\left[n\sum_{i=1}^{n} y_i^2 - \left(\sum_{i=1}^{n} y_i\right)^2\right]}} = \frac{S_{XY}}{S_X S_Y}$$

17.4 Coeficiente de Determinação, $0 \leq R^2 \leq 1$

$$R^2 = (r_{XY})^2 = \frac{\sum_{i=1}^{n}(\hat{y}_i - \overline{Y})^2}{\sum_{i=1}^{n}(y_i - \overline{Y})^2} = \frac{S_{XY}^2}{S_X^2 S_Y^2}$$

17.5 ANOVA

Na regressão linear simples, a ANOVA (Análise da Variância) decompõe a variabilidade total da variável dependente em duas componentes: a parte explicada pela regressão e a parte residual (não explicada). O teste F, avalia a significância global do modelo. No caso particular da regressão linear simples, resume-se a testar $H_0 : \beta_1 = 0$ *versus* $H_1 : \beta_1 \neq 0$.

Fonte de variação	Soma dos Quadrados SQ	Graus de liberdade gl	Média quadrática MQ	$F_{1;n-2}$
Regressão (modelo)	$SQ_{reg} = \sum_{i=1}^{n}(\hat{y}_i - \overline{Y})^2$	1	$MQ_{reg} = \frac{SQ_{reg}}{1}$	$F = \frac{MQ_{reg}}{MQ_{erro}}$
Resíduos (erro)	$SQ_{erro} = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2$	$n-2$	$MQ_{erro} = \frac{SQ_{erro}}{n-2}$	$---$
Total	$SQ_{total} = \sum_{i=1}^{n}(y_i - \overline{Y})^2$	$n-1$	$---$	$---$

Nota: $RSS = SQ_{reg}$, $ESS = SQ_{erro}$ e $TSS = SQ_{total}$.

Na regressão linear simples, tanto o teste F quanto o teste t são usados para testar se a variável explicativa tem efeito significativo sobre a variável dependente. No caso particular da regressão linear simples, $F = t^2$.